HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise)

Метод HDBSCAN представляет собой расширение алгоритма DBSCAN и предназначен для кластеризации данных с переменной плотностью. В отличие от базового подхода, он способен более гибко анализировать структуру данных за счёт построения иерархии кластеров.

Суть метода

Основная идея алгоритма заключается в объединении принципов плотностной кластеризации и иерархического анализа. Вместо фиксированного радиуса окрестности, как в DBSCAN, здесь рассматривается изменение плотности на разных уровнях.

Алгоритм сначала строит иерархическую структуру кластеров, после чего выбирает наиболее устойчивые из них. Это позволяет корректно работать даже в тех случаях, когда плотность кластеров сильно различается.

Таким образом, HDBSCAN можно рассматривать как более адаптивную и устойчивую версию DBSCAN.

Основные понятия

Минимальный размер кластера

Параметр min_cluster_size определяет минимальное количество точек, необходимое для формирования устойчивого кластера.

Core distance

Core distance — это расстояние от точки до её k-го ближайшего соседа. Оно используется для оценки локальной плотности.

Mutual reachability distance

Расстояние между двумя точками определяется как:

$$d_{mreach}(a, b) = \max\left(core_k(a), core_k(b), d(a, b)\right)$$

Это позволяет учитывать плотность вокруг точек при вычислении расстояния.

Принцип работы

Алгоритм выполняется в несколько этапов:

1. Вычисляется расстояние mutual reachability между всеми точками
2. Строится минимальное остовное дерево (MST)
3. Формируется иерархия кластеров
4. Выбираются наиболее стабильные кластеры

В результате получается разбиение данных с учётом различной плотности.

Отличие от DBSCAN

Главное отличие заключается в отсутствии необходимости задавать параметр eps. Вместо этого используется анализ плотности на разных уровнях, что делает метод более универсальным.

Реализация на Python

```
import numpy as np
import matplotlib.pyplot as plt
import hdbscan
from sklearn.datasets import make_blobs

# Генерация данных
X, _ = make_blobs(
    n_samples=400,
    centers=3,
    cluster_std=[0.3, 0.7, 1.2],
    random_state=42
)

# Создание модели
model = hdbscan.HDBSCAN(
    min_cluster_size=10,
    min_samples=5
)

# Обучение
labels = model.fit_predict(X)

# Визуализация
plt.figure(figsize=(8, 6))
plt.scatter(X[:, 0], X[:, 1], c=labels, cmap='viridis')
plt.title("HDBSCAN clustering")
plt.grid(True)
```

```
plt.savefig("hdbscan_result.png", dpi=150, bbox_inches="tight")
```

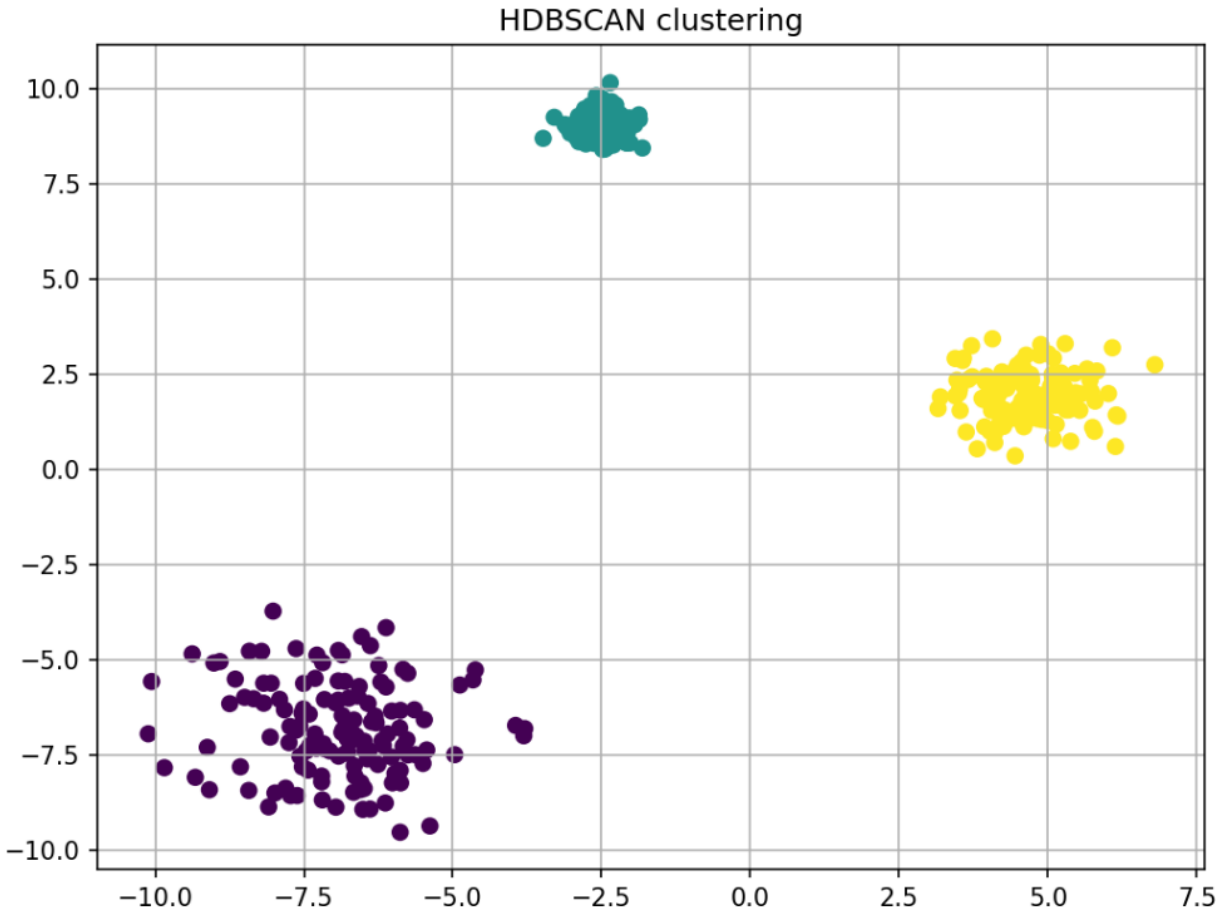

Пояснение к примеру

В данном примере создаются данные с различной плотностью кластеров. Это важно, так как именно в таких ситуациях HDBSCAN показывает свои преимущества.

После обучения алгоритм автоматически определяет кластеры и помечает шумовые точки. При этом не требуется задавать фиксированный радиус окрестности.

Основные параметры

Параметр	Описание	Влияние
min_cluster_size	минимальный размер кластера	определяет устойчивость кластеров
min_samples	параметр плотности	влияет на чувствительность к шуму
metric	метрика расстояния	задаёт способ вычисления расстояний

Достоинства метода

1. Не требует задания eps
2. Работает с переменной плотностью
3. Выявляет устойчивые кластеры
4. Автоматически определяет шум

Недостатки метода

1. Более сложная реализация
2. Более высокая вычислительная сложность
3. Требует больше времени на обучение
4. Менее интуитивная настройка параметров

Задачи для проверки понимания

Задача 1. Отличие от DBSCAN

Вопрос: Почему HDBSCAN лучше справляется с кластерами разной плотности?

Ответ:
Потому что алгоритм анализирует плотность на разных уровнях и строит иерархию кластеров. Это позволяет выявлять как плотные, так и разреженные группы, в то время как DBSCAN использует фиксированный радиус.

Задача 2. Роль min_cluster_size

Вопрос: Что произойдёт при увеличении min_cluster_size?

Ответ:
При увеличении этого параметра алгоритм будет игнорировать мелкие кластеры и оставлять только более крупные и устойчивые. В результате количество кластеров уменьшится.

Задача 3. Обнаружение шума

Вопрос: Почему HDBSCAN способен более точно выделять шум?

Ответ:
Поскольку алгоритм учитывает устойчивость кластеров на разных уровнях плотности, точки, не входящие ни в один стабильный кластер, автоматически классифицируются как шум.

Задача 4. Практический подбор параметров

Условие:
Имеется набор данных с неизвестной структурой. Требуется подобрать параметры так, чтобы получить качественное разбиение.

Решение:

```
import numpy as np
import hdbscan
from sklearn.datasets import make_blobs
from sklearn.metrics import silhouette_score

X, _ = make_blobs(
    n_samples=500,
    centers=4,
    cluster_std=[0.4, 0.6, 1.0, 1.3],
    random_state=42
)

best_score = -1
best_params = None

for size in [5, 10, 15, 20]:
    for samples in [3, 5, 7]:
        model = hdbscan.HDBSCAN(
            min_cluster_size=size,
            min_samples=samples
        )

        labels = model.fit_predict(X)

        unique_labels = set(labels)
        if -1 in unique_labels:
            unique_labels.remove(-1)

        if len(unique_labels) > 1:
            mask = labels != -1
            score = silhouette_score(X[mask], labels[mask])

            if score > best_score:
                best_score = score
                best_params = (size, samples)

print(f"Лучшие параметры: min_cluster_size={best_params[0]},
min_samples={best_params[1]}")
print(f"Silhouette Score: {best_score:.3f}")
```

Пояснение:
В данном примере осуществляется перебор параметров для поиска наиболее качественного разбиения. Оценка производится с помощью метрики силуэта, при этом шумовые точки исключаются из расчёта.

Итог

Метод HDBSCAN представляет собой развитие идей плотностной кластеризации и позволяет эффективно работать с данными сложной структуры. Его ключевым преимуществом является способность учитывать переменную плотность и автоматически выделять устойчивые кластеры. Несмотря на более высокую сложность, он часто даёт более качественные результаты по сравнению с классическими алгоритмами.