OPTICS (Ordering Points To Identify the Clustering Structure)

Метод OPTICS представляет собой алгоритм кластеризации, основанный на анализе плотности распределения объектов. По своей идее он близок к DBSCAN, однако отличается тем, что позволяет исследовать структуру данных при изменяющейся плотности, не ограничиваясь одним фиксированным значением радиуса окрестности.

Суть метода

Основная идея метода заключается в упорядочивании точек таким образом, чтобы отражать внутреннюю плотностную структуру данных. Вместо того чтобы сразу формировать окончательные кластеры, алгоритм строит специальный порядок обхода объектов и вычисляет для них значения достижимости.

Это делает метод особенно удобным в ситуациях, когда данные содержат кластеры различной плотности. Если в DBSCAN один параметр eps может подходить только части данных, то OPTICS позволяет проследить структуру более гибко.

Таким образом, OPTICS можно рассматривать как развитие подхода плотностной кластеризации, ориентированное не только на итоговое разбиение, но и на анализ самой структуры данных.

Основные понятия

eps-окрестность

Для каждой точки рассматривается множество объектов, находящихся от неё на расстоянии не более заданного значения eps. В OPTICS этот параметр обычно используется как верхняя граница анализа, а не как жёсткий критерий для выделения единственного разбиения.

min_samples

Параметр min_samples задаёт минимальное количество соседей, необходимое для признания точки достаточно плотной.

Core distance

Core distance — это минимальное расстояние, при котором точка становится ядровой, то есть получает нужное количество соседей. Если у точки недостаточно соседей, core distance не определяется.

Reachability distance

Для точки qqq, достижимой из точки ppp, расстояние достижимости определяется следующим образом:

$$\mathbf{reachability}(\mathbf{p}, \mathbf{q}) = \max(\mathbf{core_distance}(\mathbf{p}), \mathbf{d}(\mathbf{p}, \mathbf{q}))$$

Это расстояние отражает не просто близость точек, а близость с учётом плотности вокруг исходной точки.

Принцип работы

Алгоритм работает следующим образом:

1. Для каждой точки вычисляются соседи в пределах eps
2. Определяется core distance
3. Точки упорядочиваются в последовательность обхода
4. Для каждой точки вычисляется reachability distance
5. По полученному порядку и значениям достижимости анализируется структура кластеров

В результате получается не только разметка кластеров, но и так называемый график достижимости, который показывает, где находятся плотные области и как они отделяются друг от друга.

Отличие от DBSCAN

Метод DBSCAN формирует кластеры на основе одного фиксированного уровня плотности. OPTICS, напротив, позволяет исследовать данные на разных уровнях плотности и тем самым работать с более сложными структурами.

Именно поэтому OPTICS лучше подходит для случаев, когда в выборке присутствуют как плотные, так и более разреженные кластеры.

Математическая интерпретация

Пусть $N_\varepsilon(p)$ — множество соседей точки p в eps-окрестности. Тогда точка считается достаточно плотной, если:

$$|N_\varepsilon(p)| \geq min_samples$$

Тогда её core distance может быть определено как расстояние до min_samplesmin-го ближайшего соседа.

Расстояние достижимости для соседней точки рассчитывается как:

$$reachability(p, q) = \max(core_distance(p), d(p, q))$$

Чем меньше значение reachability distance, тем более естественным является включение точки в плотную область.

Реализация на Python

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import OPTICS
from sklearn.datasets import make_blobs

# Генерация данных
X, _ = make_blobs(
    n_samples=400,
    centers=4,
    cluster_std=[0.3, 0.5, 0.8, 1.2],
    random_state=42
)

# Создание модели
model = OPTICS(
    min_samples=5,
    xi=0.05,
    min_cluster_size=0.05
)

# Обучение модели
labels = model.fit_predict(X)

# Визуализация кластеров
plt.figure(figsize=(8, 6))
plt.scatter(X[:, 0], X[:, 1], c=labels, cmap='viridis')
plt.title("OPTICS clustering")
plt.grid(True)
plt.show()

# График достижимости
space = np.arange(len(X))
reachability = model.reachability_[model.ordering_]
labels_ordered = labels[model.ordering_]

plt.figure(figsize=(10, 6))
plt.plot(space, reachability, marker='.', linestyle='none')
plt.title("Reachability Plot")
plt.xlabel("Порядок точек")
plt.ylabel("Reachability distance")
```

```
plt.grid(True)
plt.show()
```

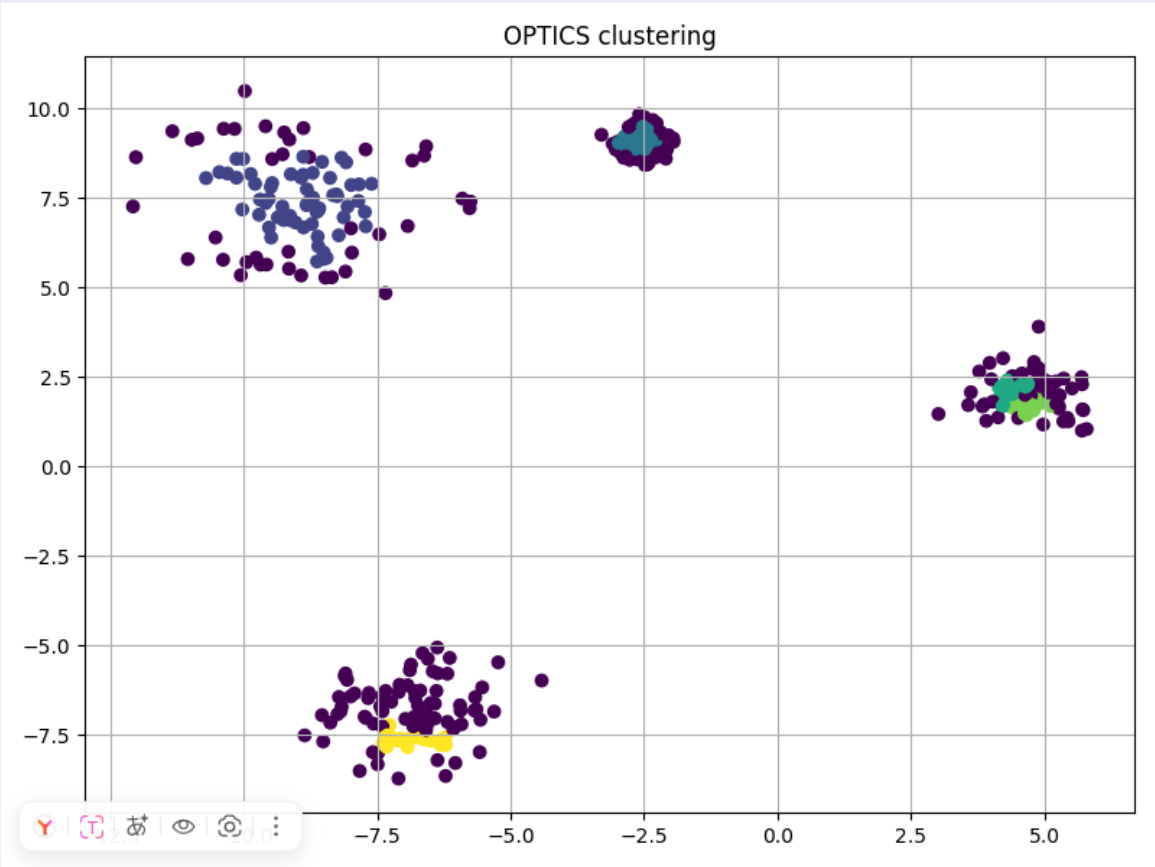

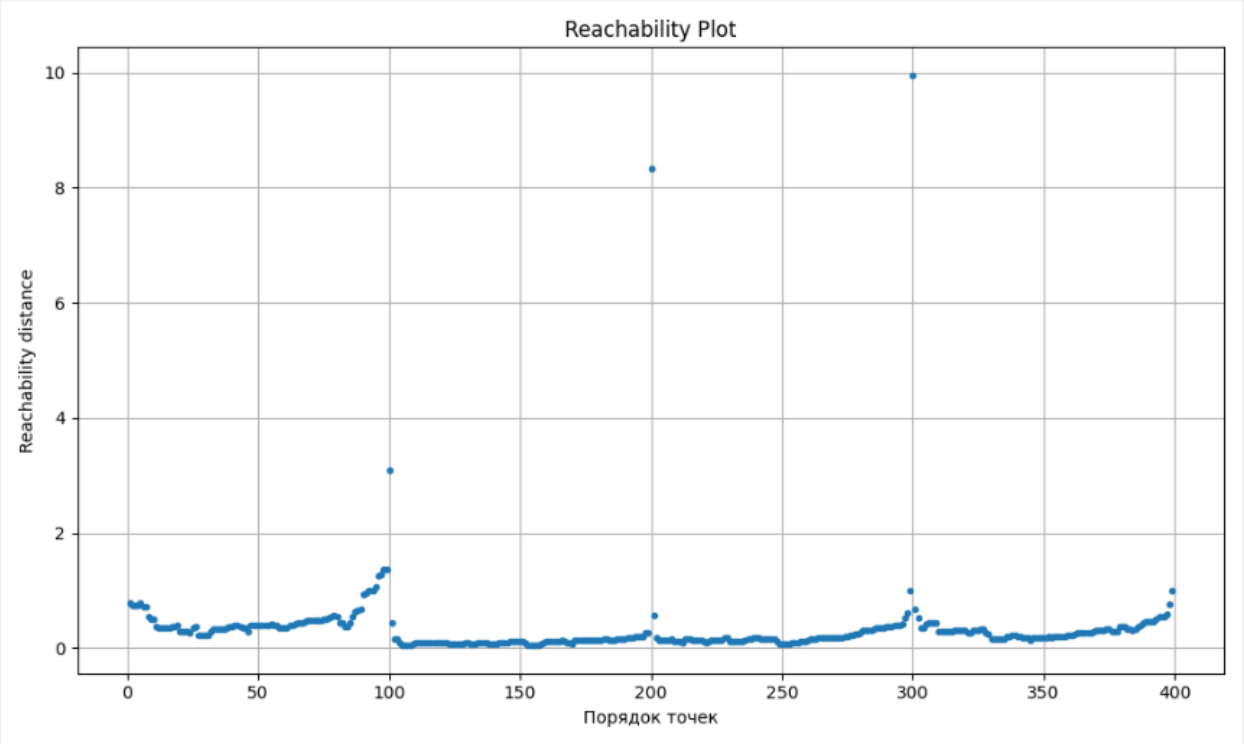

Пояснение к примеру

В данном примере создаётся набор данных, содержащий несколько кластеров с разной плотностью. Это как раз та ситуация, в которой OPTICS показывает свои сильные стороны.

После обучения алгоритм возвращает метки кластеров. Дополнительно можно построить график достижимости, который даёт более глубокое представление о структуре выборки. Низкие участки на этом графике соответствуют плотным областям, а резкие подъёмы часто указывают на границы между кластерами.

Основные параметры

Параметр	Описание	Влияние
min_samples	минимальное число соседей	влияет на плотность и чувствительность к шуму
max_eps	максимальный радиус анализа	ограничивает диапазон поиска соседей
xi	параметр выделения кластеров	определяет чувствительность к перепадам плотности
min_cluster_size	минимальный размер кластера	отсекает слишком малые группы

Достоинства метода

1. Не требует жёсткого выбора одного eps
2. Позволяет анализировать кластеры разной плотности
3. Хорошо работает со сложной структурой данных
4. Даёт дополнительный инструмент анализа в виде графика достижимости

Недостатки метода

1. Более сложен для понимания по сравнению с DBSCAN
2. Требует интерпретации графика достижимости
3. Вычислительно тяжелее простых методов
4. Результат может зависеть от выбора параметров xi и min_samples

Задачи для проверки понимания

Задача 1. Отличие от DBSCAN

Вопрос: В чём основное преимущество OPTICS по сравнению с DBSCAN?

Ответ:
Основное преимущество OPTICS заключается в том, что он не привязан к

одному фиксированному значению плотности. Благодаря этому метод способен выявлять кластеры разной плотности, тогда как DBSCAN лучше работает только в том случае, когда подходящий уровень плотности примерно одинаков для всей выборки.

Задача 2. Роль reachability distance

Вопрос: Для чего в алгоритме используется reachability distance?

Ответ:
Reachability distance показывает, насколько естественно одна точка может быть достигнута из другой с учётом локальной плотности. За счёт этого параметра алгоритм может упорядочивать точки так, чтобы плотные области выделялись как непрерывные участки с малыми значениями достижимости.

Задача 3. Интерпретация графика

Вопрос: Что означают низкие участки на графике достижимости?

Ответ:
Низкие участки соответствуют плотным областям данных. Если несколько точек имеют малые значения reachability distance подряд, это обычно указывает на наличие кластера. Высокие скачки, напротив, часто обозначают границы между различными группами или присутствие шума.

Задача 4. Практический подбор параметров

Условие:
Имеется набор данных с неизвестной структурой. Требуется подобрать параметры min_samples и xi, чтобы получить наиболее качественное разбиение.

Решение:

```
import numpy as np
from sklearn.cluster import OPTICS
from sklearn.datasets import make_blobs
from sklearn.metrics import silhouette_score

X, _ = make_blobs(
    n_samples=500,
    centers=4,
    cluster_std=[0.4, 0.7, 1.0, 1.3],
    random_state=42
)
```

```
best_score = -1
best_params = None
best_clusters = None

for min_samples in [3, 5, 7, 10]:
    for xi in [0.03, 0.05, 0.07, 0.1]:
        model = OPTICS(
            min_samples=min_samples,
            xi=xi,
            min_cluster_size=0.05
        )

        labels = model.fit_predict(X)

        unique_labels = set(labels)
        if -1 in unique_labels:
            unique_labels.remove(-1)

        n_clusters = len(unique_labels)

        if n_clusters > 1:
            mask = labels != -1
            score = silhouette_score(X[mask], labels[mask])

            if score > best_score:
                best_score = score
                best_params = (min_samples, xi)
                best_clusters = n_clusters

print(f"Лучшие параметры: min_samples={best_params[0]},
xi={best_params[1]}")
print(f"Количество кластеров: {best_clusters}")
print(f"Silhouette Score: {best_score:.3f}")
```

Пояснение:
В данном примере осуществляется перебор нескольких значений параметров. Для каждого варианта вычисляется число найденных кластеров и оценивается качество разбиения с помощью метрики силуэта. Шумовые точки при этом исключаются из оценки, поскольку они не принадлежат устойчивым кластерам.

Итог

Метод OPTICS представляет собой мощный инструмент плотностной кластеризации, позволяющий исследовать внутреннюю структуру данных

значительно глубже, чем это делает DBSCAN. Его основное преимущество связано со способностью анализировать кластеры переменной плотности и строить график достижимости, который помогает интерпретировать распределение объектов. При этом метод требует более внимательного подхода к анализу результатов и настройке параметров.