Иерархическая кластеризация (Hierarchical Clustering)

Иерархическая кластеризация представляет собой метод группировки данных, основанный на последовательном объединении или разделении объектов. В отличие от многих алгоритмов, она формирует не одно фиксированное разбиение, а целую иерархию кластеров, что позволяет более глубоко анализировать структуру данных.

Суть метода

Основная идея заключается в построении дерева кластеров, называемого дендрограммой. Это дерево отражает процесс объединения или разделения объектов на разных уровнях.

Существует два основных подхода:

- агломеративный — начинается с отдельных точек и последовательно объединяет их
- дивизивный — начинается с одного кластера и последовательно делит его

На практике чаще используется агломеративный подход.

Принцип работы (агломеративный метод)

Алгоритм выполняется следующим образом:

1. Каждая точка рассматривается как отдельный кластер
2. Вычисляются расстояния между всеми кластерами
3. Находятся два ближайших кластера
4. Эти кластеры объединяются
5. Процесс повторяется до тех пор, пока не останется один кластер

Результат можно представить в виде дендрограммы.

Методы объединения (linkage)

При объединении кластеров важно определить расстояние между ними. Для этого используются различные методы:

- single linkage — минимальное расстояние между точками кластеров
- complete linkage — максимальное расстояние
- average linkage — среднее расстояние
- ward linkage — минимизация внутрикластерной дисперсии

Математическая интерпретация

Например, для метода average linkage расстояние между кластерами вычисляется как:

$$d(A, B) = \frac{1}{|A| \cdot |B|} \sum_{a \in A} \sum_{b \in B} d(a, b)$$

Это означает, что учитываются расстояния между всеми парами точек.

Дендрограмма

Дендрограмма представляет собой дерево, где:

- листья — это отдельные точки
- узлы — объединения кластеров
- высота — расстояние между объединяемыми кластерами

Срезая дендрограмму на определённой высоте, можно получить нужное количество кластеров.

Реализация на Python

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import AgglomerativeClustering
from scipy.cluster.hierarchy import dendrogram, linkage
from sklearn.datasets import make_blobs

# Генерация данных
X, _ = make_blobs(
    n_samples=300,
    centers=4,
    cluster_std=0.7,
    random_state=42
)

# Построение дендрограммы
Z = linkage(X, method='ward')

plt.figure(figsize=(10, 6))
dendrogram(Z)
plt.title("Dendrogram")
plt.show()

# Кластеризация
```

```
model = AgglomerativeClustering(n_clusters=4, linkage='ward')
labels = model.fit_predict(X)

# Визуализация
plt.figure(figsize=(8, 6))
plt.scatter(X[:, 0], X[:, 1], c=labels, cmap='viridis')
plt.title("Hierarchical clustering")
plt.grid(True)
plt.show()
```

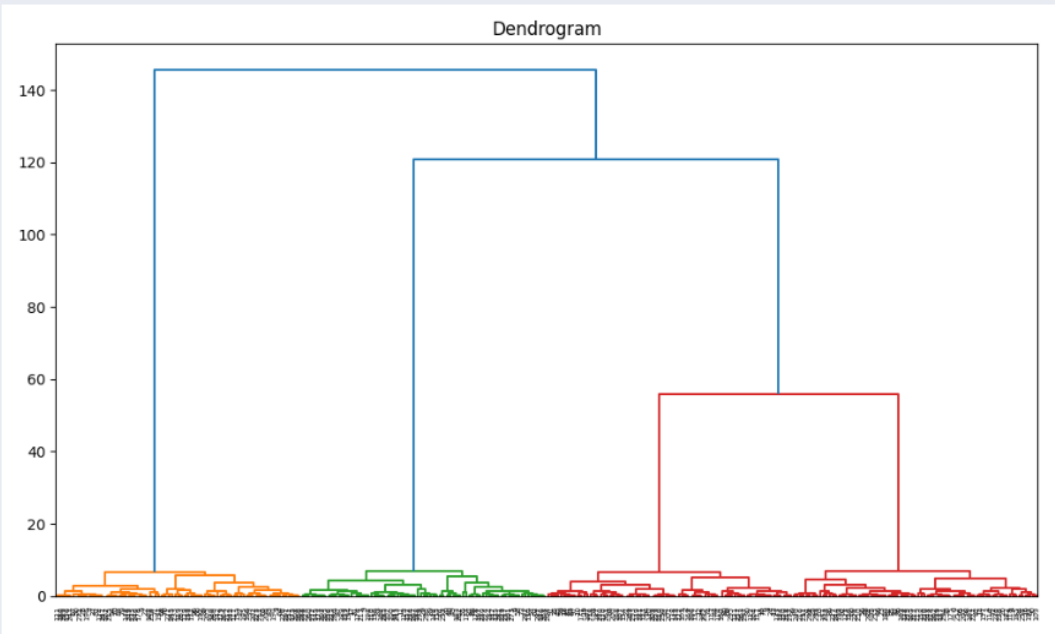

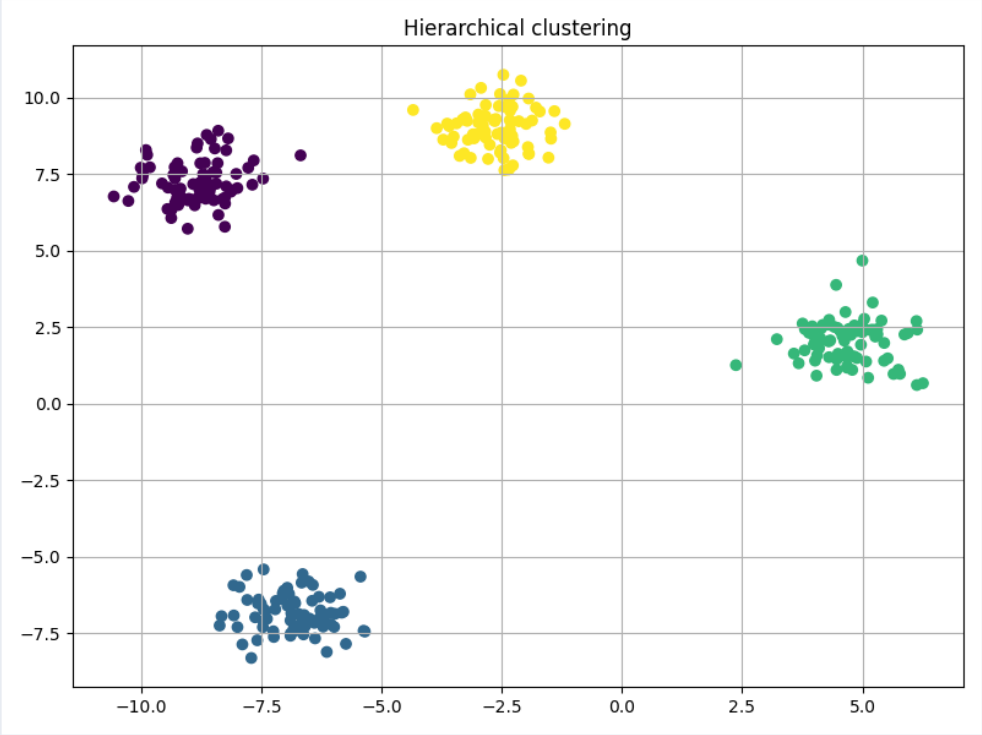

Пояснение к примеру

Сначала строится дендрограмма, позволяющая визуально оценить структуру данных. Затем выполняется кластеризация с заданным числом кластеров.

Использование метода Ward позволяет получать более компактные и сбалансированные кластеры.

Достоинства метода

1. Не требует заранее задавать число кластеров
2. Позволяет анализировать структуру данных на разных уровнях
3. Даёт наглядную визуализацию (дендрограмма)
4. Прост в интерпретации

Недостатки метода

1. Высокая вычислительная сложность
2. Плохо масштабируется на больших данных
3. Чувствителен к выбросам
4. Необратимость объединений

Задачи для проверки понимания

Задача 1. Выбор числа кластеров

Вопрос: Как определить количество кластеров с помощью дендрограммы?

Ответ:
Количество кластеров определяется путём "среза" дендрограммы на определённой высоте. Обычно выбирается уровень, где расстояние между объединениями резко увеличивается, что указывает на естественные границы между кластерами.

Задача 2. Влияние метода linkage

Вопрос: Чем отличается single linkage от complete linkage?

Ответ:
Single linkage учитывает минимальное расстояние между точками, что может приводить к эффекту "цепочек". Complete linkage использует максимальное расстояние, что делает кластеры более компактными и разделёнными.

Задача 3. Ограничения метода

Вопрос: Почему алгоритм плохо работает на больших данных?

Ответ:
Поскольку требуется вычислять расстояния между всеми парами объектов,

сложность алгоритма возрастает квадратично, что делает его неэффективным при большом количестве точек.

Задача 4. Практический анализ

Условие:
Дан набор данных. Требуется определить оптимальное число кластеров с помощью дендрограммы.

Решение:

```
import numpy as np
from scipy.cluster.hierarchy import linkage, dendrogram
import matplotlib.pyplot as plt
from sklearn.datasets import make_blobs

X, _ = make_blobs(
    n_samples=200,
    centers=5,
    cluster_std=0.8,
    random_state=42
)

Z = linkage(X, method='ward')

plt.figure(figsize=(10, 6))
dendrogram(Z)
plt.axhline(y=10, color='r', linestyle='--')
plt.title("Выбор числа кластеров по дендрограмме")
plt.show()
```

Пояснение:
Горизонтальная линия показывает уровень среза. Количество пересечённых ветвей соответствует числу кластеров.

Итог

Иерархическая кластеризация представляет собой мощный инструмент анализа структуры данных, позволяющий выявлять взаимосвязи между объектами на разных уровнях. Благодаря визуализации в виде дендрограммы, данный метод особенно полезен для исследовательских задач. Однако высокая вычислительная сложность ограничивает его применение на больших наборах данных.