## Спектральная кластеризация

Спектральная кластеризация представляет собой метод разбиения данных, основанный на анализе графовой структуры и спектральных свойств матриц, описывающих взаимосвязи между объектами. В отличие от классических алгоритмов, таких как K-means, данный подход не требует предположения о форме кластеров и способен эффективно работать со сложными структурами данных.

## Суть метода

Основная идея спектральной кластеризации заключается в том, чтобы представить данные в виде графа, где вершины соответствуют объектам, а рёбра отражают степень их сходства. После этого анализируется матрица связности или лапласиан графа, и на основе его собственных значений и собственных векторов производится переход в новое пространство признаков.

В этом новом пространстве объекты становятся более разделимыми, после чего к ним можно применить простой алгоритм, например K-means.

Таким образом, метод сочетает в себе идеи линейной алгебры и кластеризации.

## Представление данных в виде графа

Для применения алгоритма необходимо определить меру сходства между объектами. Обычно используется гауссово ядро:

$$w_{ij} = \exp\left(-\frac{||x_i - x_j||^2}{2\sigma^2}\right)$$

где:

- wij — степень сходства между объектами
- σ — параметр масштаба

На основе этих значений формируется матрица смежности.

## Лапласиан графа

Одним из ключевых элементов метода является лапласиан графа:

$$L=D-W$$

где:

- D — диагональная матрица степеней вершин
- W — матрица смежности

Также используется нормализованный лапласиан:

$$L_{norm} = D^{-1/2} L D^{-1/2}$$

Анализ собственных значений и векторов этой матрицы позволяет выявить структуру кластеров.

**Принцип работы алгоритма**

Алгоритм выполняется следующим образом:

1. Строится матрица сходства объектов
2. Формируется лапласиан графа
3. Вычисляются собственные векторы
4. Выбираются k наименьших собственных значений
5. Формируется новое пространство признаков
6. Применяется K-means

Таким образом, кластеризация выполняется не напрямую в исходном пространстве, а в преобразованном.

**Особенности метода**

- не требует предположений о форме кластеров
- хорошо работает с нелинейно разделимыми данными
- использует свойства графов и линейной алгебры

**Реализация на Python**

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import SpectralClustering
from sklearn.datasets import make_moons

# Генерация данных сложной формы
X, _ = make_moons(n_samples=300, noise=0.05, random_state=42)

# Модель спектральной кластеризации
model = SpectralClustering(
    n_clusters=2,
```

```
    affinity='nearest_neighbors',
    n_neighbors=10,
    random_state=42
)

labels = model.fit_predict(X)

# Визуализация
plt.figure(figsize=(8, 6))
plt.scatter(X[:, 0], X[:, 1], c=labels, cmap='viridis')
plt.title("Spectral Clustering")
plt.grid(True)
plt.show()
```

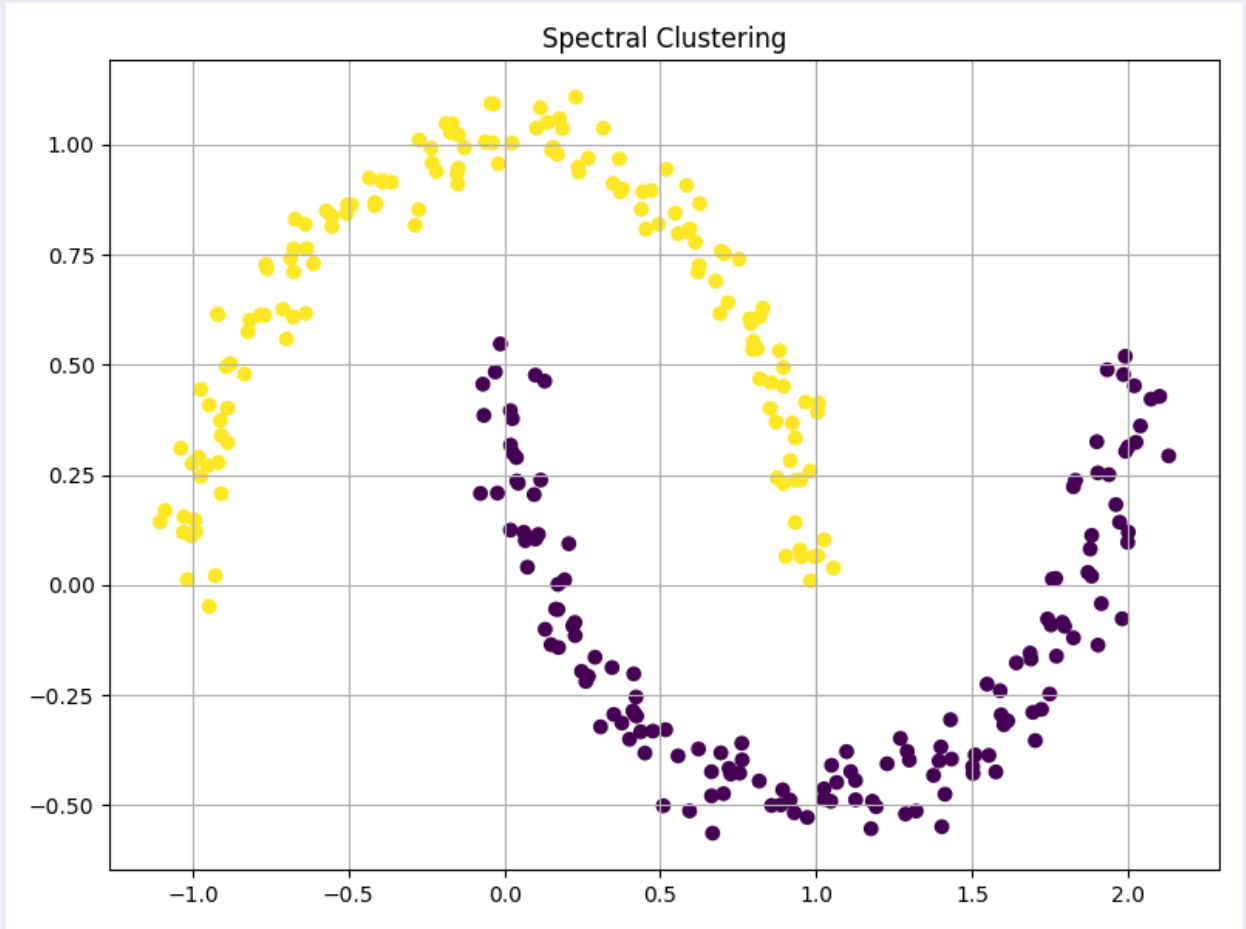


**Пояснение к примеру**

В данном примере используется набор данных, имеющий форму двух полумесяцев. Такие данные плохо разделяются методом K-means, поскольку кластеры имеют нелинейную форму.

Спектральная кластеризация позволяет преобразовать пространство таким образом, что кластеры становятся линейно разделимыми, после чего успешно выделяются.

**Основные параметры**

| Параметр | Описание |
|---|---|
| n_clusters | число кластеров |
| affinity | способ вычисления сходства |
| n_neighbors | число соседей |
| gamma | параметр гауссова ядра |

**Достоинства метода**

1. Работает со сложной геометрией данных
2. Не требует линейной разделимости
3. Универсальность применения
4. Высокое качество кластеризации

**Недостатки метода**

1. Высокая вычислительная сложность
2. Требует построения матрицы сходства
3. Плохо масштабируется на большие выборки
4. Чувствителен к параметрам

**Задачи для проверки понимания**

**Задача 1. Отличие от K-means**

Вопрос: Почему спектральная кластеризация лучше работает с нелинейными структурами?

Ответ:
Потому что она преобразует исходное пространство данных с помощью спектрального разложения графа, делая сложные структуры более разделимыми, в отличие от K-means, который работает напрямую в исходном пространстве.

**Задача 2. Роль лапласиана**

Вопрос: Для чего используется лапласиан графа?

Ответ:
Лапласиан отражает структуру связей между объектами и позволяет выявить группы с высокой внутренней связностью и слабой связностью между группами.

**Задача 3. Интерпретация параметров**

Вопрос: Как влияет параметр n_neighbors?

Ответ:
Он определяет, сколько соседей учитывается при построении графа. Малое значение может привести к разрыву графа, а слишком большое — к потере локальной структуры.

**Задача 4. Практическое сравнение**

Условие:
Сравнить K-means и спектральную кластеризацию на сложных данных.

Решение:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans, SpectralClustering
from sklearn.datasets import make_moons

X, _ = make_moons(n_samples=400, noise=0.06, random_state=42)

kmeans = KMeans(n_clusters=2, random_state=42)
spec = SpectralClustering(n_clusters=2, affinity='nearest_neighbors')

labels_k = kmeans.fit_predict(X)
labels_s = spec.fit_predict(X)

plt.figure(figsize=(12, 5))

plt.subplot(1, 2, 1)
plt.scatter(X[:, 0], X[:, 1], c=labels_k, cmap='viridis')
plt.title("K-means")

plt.subplot(1, 2, 2)
plt.scatter(X[:, 0], X[:, 1], c=labels_s, cmap='viridis')
plt.title("Spectral Clustering")

plt.show()
```

Пояснение:
В данном примере K-means не способен корректно разделить данные из-за их формы. Спектральная кластеризация, напротив, успешно выделяет кластеры благодаря анализу графовой структуры.

**Итог**

Спектральная кластеризация представляет собой мощный метод анализа данных, основанный на преобразовании пространства с использованием спектральных свойств графов. Она позволяет эффективно работать с данными сложной формы и выявлять скрытую структуру, недоступную для более простых алгоритмов. Несмотря на более высокую вычислительную сложность, данный метод широко применяется в задачах анализа изображений, социальных сетей и других областях, где структура данных имеет нелинейный характер.